

淘宝数据处理流程报告

1. 数据读取

使用python初步读取数据并查看：

```
数据形状: (12256906, 5)
内存占用: 619.52 MB
数据类型:
time          str
user_id       int64
item_id       int64
item_category int64
behavior_type int64
dtype: object
```

本项目数据集包含约 1226 万条用户行为记录。考虑到数据规模较大，直接使用 Pandas 全量加载可能产生较高的内存开销，因此采用 Dask 进行分块读取和计算，并结合数据类型优化。最终转换为Parquet存储提升数据处理效率。本研究使用Dask将数据分为3份。

2. 数据清洗

变量类型可分为以下几类：

```
ID变量: 'user_id', 'item_id'
类别变量: 'item_category', 'behavior_type'
时间变量: 'time'
```

数据不存在连续型数值变量，因此不适用基于IQR或 3σ 的连续变量异常值检测方法。针对本数据集，异常值识别主要依据业务规则和字段取值范围。

首先查看类别变量behavior_type取值范围，并未发现1~4范围外的异常值。其次对检查数据中是否有负值或0值，结果未发现异常。检查缺失值，同样未发现变量存在缺失。最后检查时间变量，其存储格式为格式为 YYYY-MM-DD HH ,精确到小时，后续需要进行处理。

接下来基于用户-商品-行为-时间四元组去重，检查是否存在重复记录的数据，发现存在重复四元组数量3843197条。删除重复，每条只保留一行，得到：

```
去重前行数: 12,256,906
去重后行数: 6,213,379
删除重复行: 6,043,527
```

统一时间格式，补齐为 YYYY-MM-DD HH:00:00，并校验时间有效性，确保不存在转换失败的数据。时间范围从2025-11-18 00:00:00 到 2025-12-18 23:00:00，时长一个月。确认时间变量已经被转换为datetime64类型。

3. 自动化数据检验脚本

为高效实现数据完整性、一致性、唯一性的批量检测，定义函数，实现自动化数据质量校验脚本。输出的数据检测报告如下：

```
=====
数据质量校验报告
=====

检测时间：2026-09-07 00:07:37

数据总行数：6213379

数据总列数：5

完整性_缺失值检测：通过

一致性_时间无效数量：0

一致性_时间范围：2025-11-18 00:00:00 至 2025-12-18 23:00:00

唯一性_检测结果：通过，无重复


完整性_缺失明细：
Empty DataFrame
Columns: [缺失数量, 缺失率%]
Index: []

一致性_ID变量检查：
      user_id  item_id
零值数量      0      0
负值数量      0      0

一致性_类别变量取值分布：

item_category:
item_category
3             2
8           496
10          129
21           88
28           61
...
14051        32
14056        15
14066       120
14074         4
14080        49
Name: count, Length: 8916, dtype: int64

behavior_type:
behavior_type
3       331350
1     5535879
2     239472
4     106678
Name: count, dtype: int64
```

4. 中间表构建

构建用户、商品、时间三个维度的基础聚合中间表。

其中用户维度中间表主键为user_id, 统计每个用户的整体行为, 包括总行为次数、各类行为次数(浏览、点击、购买等)、活跃天数、最早/最晚行为时间。

商品维度中间表主键为item_id, 统计每个商品的表现, 包括行为总次数、各类行为次数、独立用户数(多少用户进行过操作)、首次/最后出现时间。

时间维度中间表按日期聚合, 统计每天电商平台的整体情况, 包括行为总次数、各类行为次数、活跃用户数, 活跃商品数。

DataFrame总结如下:

用户维度中间表构建完成

用户数量: 10,000

商品维度中间表构建完成

商品数量: 2,876,947

时间维度中间表构建完成

日期数量: 31

为保证数据类型正确, 对每一张表进行检查。时间表的 date 列还是 object, 转成标准日期类型。至此完成全流程数据清洗以及中间表构建。将清洗后的用户行为主表和三张中间表以 **Parquet** 格式输出。