

淘宝用户行为数据分析

一、项目背景

当前电商领域数据规模呈爆发式增长,海量用户行为数据中蕴含着用户偏好、商品价值、转化规律等核心商业价值,数据驱动已成为电商平台精细化运营的核心竞争力。本实习项目聚焦淘宝用户行为数据,以数据工程能力培养、深度特征挖掘、多模型建模实践、业务价值转化为核心目标,通过系统化的数据分析全流程、工程化落地规范及算法建模任务,全面提升实习生在大数据处理、特征工程、模型构建与评估、业务洞察等方面的核心技能。

项目将围绕以下核心业务问题展开实践: 如何高效处理亿级规模用户行为数据,保障数据质量与处理效率? 如何构建多维度、有区分度的特征体系,支撑后续建模任务? 如何通过逻辑回归模型实现用户购买行为的精准预测? 如何利用深度学习模型捕捉用户序列行为规律,提升预测效果? 如何通过数据分析与建模结果,提炼可落地的业务洞察与决策建议?

二、数据概况

2.1 数据来源与规模

本项目采用淘宝用户行为数据集,包含用户行为记录,覆盖约100万独立用户和400万件商品,完整记录了用户在平台上的浏览、收藏、加购、购买全链路交互行为。

2.2 数据集字段说明

字段名	数据类型	取值范围	详细说明
user_id	string	约100万种	用户唯一标识,用于区分不同用户
item_id	string	约400万种	商品唯一标识,用于区分不同商品
category_id	string	约1万种	商品类目唯一标识,用于划分商品所属品类
behavior_type	string	1/2/3/4	用户对商品的行为类型: 1=浏览(pv) 2=收藏(fav) 3=加购物车(cart) 4=购买(buy)
timestamp	string	-	行为发生的时间戳,格式为 YYYY-MM-DD HH,精确到小时

第一阶段:数据工程体系搭建与理论储备

核心目标

完成大数据处理环境与工程化管理体系搭建,建立电商用户行为分析的理论基础,实现数据全流程自动化处理与质量管控。

具体任务

- 工程化环境与版本管理搭建 配置Python大数据分析环境(Pandas、Dask、NumPy、PyArrow),针对数据规模优化内存分配与计算资源调度 搭建Git版本管理体系,制定Commit Message规范与分支管理策略(main/dev/feature三级分支),所有代码、文档、中间结果按目录规范同步至仓库 设计模块化项目目录结构,实现数据层、代码层、文档层、结果层的完全解耦
- 领域文献调研与技术栈储备 精读3-5篇电商用户行为预测经典论文(如《Deep Interest Network for CTR Prediction》《Wide & Deep Learning for Recommender Systems》《Behavior Sequence Transformer》等),梳理核心算法思想与特征工程范式 调研行业主流电商数据分析技术方案,对比不同工具(Spark vs Dask)、模型在亿级数据场景下的优劣
- 亿级数据加载与全流程清洗 完成数据集的获取与合规性校验,设计分块读取+并行处理方案,解决单节点内存溢出问题 执行多维度数据清洗:基于业务规则与IQR/ 3σ 法则处理异常值,基于用户-商品-行为-时间四元组去重,统一时间格式并校验时间有效性 开发自动化数据质量校验脚本,实现数据完整性、一致性、唯一性的批量检测,生成可追溯的质量报告
- 数据预处理与中间表构建 完成数据类型压缩(如字符串转类别型、数值型精度适配)与非必要字段筛选,将数据转换为Parquet格式提升读写效率 构建用户、商品、时间三个维度的基础聚合中间表,为后续特征工程做预计算

交付成果

符合规范的Git项目仓库(含完整目录结构与提交记录) 领域文献调研笔记 数据处理自动化脚本集(加载、清洗、质量校验、格式转换) 数据处理报告(含处理逻辑、质量评估结果、中间表设计说明) 预处理后的标准化数据集(Parquet格式)

第二阶段:深度特征工程与多维度探索性分析

核心目标

构建多维度、高区分度的特征体系,通过全面的探索性数据分析挖掘用户行为规律与特征关联,为建模提供高质量输入。

具体任务

1. SQLite数据库搭建与SQL基础分析

- 设计符合第三范式的SQLite数据库表结构, 创建用户行为主表、用户维度表、商品维度表、时间维度表
- 编写批量数据导入脚本, 将预处理后的Parquet格式数据高效导入SQLite数据库, 建立索引优化查询性能
- 掌握SQL核心语法, 完成基础数据统计分析: 用户行为总量统计、各行为类型占比计算、日活/周活趋势查询、热门商品与类目排名
- 实现复杂SQL查询: 用户行为序列提取、转化漏斗各环节数据计算、用户分群统计、商品复购率分析
- 建立Python与SQLite的交互接口, 实现SQL查询结果与Pandas DataFrame的无缝转换, 支持后续深度分析

2. 全维度特征体系构建 基础特征扩展:在原有用户、商品、时间特征基础上,新增用户生命周期特征(活跃度等级、连续活跃天数、流失间隔)、商品生命周期特征(热度衰减系数、类目竞争度)、行为序列特征(相邻行为间隔、行为跳转概率、连续行为模式) 隐式特征挖掘:基于用户-商品交互矩阵,通过SVD矩阵分解提取用户与商品的隐式语义特征;计算用户-商品、商品-商品的共现相似度与关联规则特征 业务导向特征:基于RFM模型计算用户价值分,构建全链路转化漏斗特征(浏览-加购、加购-收藏、收藏-购买各环节转化率),设计用户偏好强度得分(行为权重:购买>加购>收藏>浏览)
3. 特征预处理与有效性验证 完成数值型特征标准化/归一化、类别型特征编码(Target Encoding替代独热编码处理高维类目特征),针对稀疏特征实现预嵌入处理 通过相关性分析、互信息法、方差阈值法进行特征筛选,剔除冗余特征与低区分度特征 验证特征与目标变量(用户未来7天是否购买)的相关性,输出特征重要性预评估报告
4. 多维度探索性数据分析 基础行为分析:统计用户行为类型分布、日活/周活趋势、用户活跃时段分布,识别高转化时段 转化漏斗分析:拆解用户从浏览到购买的全链路转化效率,定位核心流失节点 用户分群分析:基于RFM模型将用户分为高价值、潜力、流失、沉睡四类,对比不同群体的行为特征与转化差异 商品分析:挖掘热门类目与爆款商品特征,分析不同类目商品的转化周期与复购率 时间维度分析:对比工作日与周末、节假日与非节假日的用户行为差异

交付成果

SQLite数据库文件(含完整表结构与索引) SQL查询脚本集(基础统计、转化分析、用户分群等) Python-SQLite交互工具类 完整的特征字典(含特征定义、计算逻辑、预处理方法、区分度评估) 特征工程脚本集与预处理后的特征数据集 特征有效性评估报告(含相关性热力图、重要性排序) 探索性数据分析报告(含至少8种核心可视化图表) 核心数据洞察总结(含用户行为规律、转化瓶颈、商品运营建议)

第三阶段:多模型建模与性能优化

核心目标

完成传统机器学习与深度学习模型的全流程构建与调优,对比不同模型的性能差异,深入分析模型可解释性,探索模型融合方案提升预测效果。

具体任务

1. 样本构建与数据集划分 明确目标变量定义(用户-商品对未来7天是否产生购买行为),构建正负样本集 采用分层抽样按7:2:1划分训练集、验证集、测试集,保证各数据集分布一致性 对比SMOTE过采样、欠采样与类别权重调整三种方案,解决购买样本占比低的类别不平衡问题
2. 传统机器学习模型构建与调优 实现逻辑回归、XGBoost、LightGBM三种分类模型,完成模型初始化与基础训练 采用Optuna自动超参数调优框架,优化模型关键参数,以AUC为核心评估指标 对比三种传统模型的性能(AUC、准确率、召回率、F1分数),分析各自的优势场景与局限性
3. 深度学习模型构建与优化 实现基础序列模型(LSTM/GRU)与电商场景专用模型(DIN深度兴趣网络),完成序列数据构建与特征嵌入 优化模型架构:调整嵌入维度、隐藏层单元数、Dropout比例,引入多头注意力机制提升序列特征提取能力 采用学习率衰减、早停(Early Stopping)策略防止过拟合,对比不同深度学习模型与传统模型的性能差异
4. 模型融合与可解释性分析 设计Stacking模型融合方案,融合逻辑回归、XGBoost与DIN模型的预测结果,进一步提升整体性能 深入分析模型可解释性:基于特征系数解释逻辑回归,基于SHAP值解释XGBoost与DIN模型,识别影响用户购买决策的核心特征 分析模型预测错误样本的特征,总结模型在冷启动用户、长尾商品场景下的不足
5. 业务落地模拟设计 基于模型预测结果,设计模拟A/B测试方案,明确实验分组、核心评估指标与实验周期 提出基于模型的精准营销与商品推荐优化建议,量化预期业务收益

交付成果

单模型性能评估报告 模型融合方案与性能对比报告 模型可解释性分析报告(含SHAP可视化结果) 模拟A/B测试方案与业务落地建议

第四阶段:成果沉淀与项目复盘

核心目标

完成项目成果的系统化整理与可复用封装,进行全面的项目复盘,提升技术总结与表达能力。

具体任务

1. 代码工程化封装 将数据处理、特征工程、模型训练、预测推理等模块封装为可复用的Python工具包,编写API文档与使用示例 完善代码注释与单元测试,提升代码的

可读性与健壮性

2. 项目文档与汇报材料撰写 撰写完整的项目总报告,涵盖项目背景、数据概况、技术方案、实验结果、核心洞察与业务建议 制作项目汇报PPT与技术分享PPT,梳理项目核心亮点与技术难点
3. 项目复盘与总结 复盘项目全流程,总结数据处理、特征工程、建模过程中遇到的问题与解决方案 分析项目存在的局限性,提出后续优化方向(如引入Transformer架构、扩充外部数据、增加实时特征等)
4. 成果提交与展示 整理所有项目成果,同步至Git仓库main分支,生成版本发布记录 进行项目成果汇报与技术分享

交付成果

可复用的电商用户行为分析Python工具包(含API文档与使用示例) 完整的项目总报告(含所有分析与建模结果) 项目汇报PPT与技术分享PPT 最终Git仓库