

淘宝用户行为数据分析报告

一、研究背景

当前电商领域数据规模呈爆发式增长，海量用户行为数据中蕴含着用户偏好、商品价值、转化规律等核心商业价值，数据驱动已成为电商平台精细化运营的核心竞争力。本研究聚焦淘宝用户行为数据，实践从亿级数据处理、特征工程、机器学习建模到业务分析的全过程。以预测用户未来七天购买行为为目标，建立传统机器学习模型、深度学习模型、DIN模型及Stacking模型融合方案。通过指标评估模型效果，并分析模型可解释性，把模型结果转化为可落地的商业决策建议。设计模拟A/B testing方案，量化预期业务收益并提出建议。

项目理解：

围绕淘宝用户行为数据，实践从亿级数据处理、特征工程、机器学习建模到业务分析的全过程。具体流程：

1. 数据工程。对原始数据进行清洗及格式统一，并通过合理的数据处理方式提高海量数据的处理效率，为后续分析提供数据基础
2. 特征工程。结合业务背景从不同维度构建特征。完成特征预处理与有效性验证，为后续建模准备
3. 预测建模。结合传统机器学习模型和深度学习模型，预测用户购买决策和影响因素，深入挖掘用户行为规律
4. 业务价值转化。通过指标评估模型效果，并分析模型可解释性，把模型结果转化为可落地的商业决策建议

二、数据处理流程

1. 数据读取

使用python初步读取数据并查看：

数据形状: (12256906, 5)

内存占用: 619.52 MB

数据类型:

```
time          str
user_id       int64
item_id       int64
item_category int64
behavior_type int64
dtype: object
```

本项目数据集包含约 1226 万条用户行为记录。考虑到数据规模较大, 直接使用 Pandas 全量加载可能产生较高的内存开销, 因此采用 Dask 进行分块读取和计算, 并结合数据类型优化。最终转换为Parquet存储提升数据处理效率。本研究使用Dask将数据分为3份。

2. 数据清洗

变量类型可分为以下几类:

```
ID变量: 'user_id', 'item_id'
类别变量: 'item_category', 'behavior_type'
时间变量: 'time'
```

数据不存在连续型数值变量, 因此不适用基于IQR或 3σ 的连续变量异常值检测方法。针对本数据集, 异常值识别主要依据业务规则和字段取值范围。

首先查看类别变量behavior_type取值范围, 并未发现1~4范围外的异常值。其次对检查数据中是否有负值或0值, 结果未发现异常。检查缺失值, 同样未发现变量存在缺失。最后检查时间变量, 其存储格式为格式为 YYYY-MM-DD HH ,精确到小时, 后续需要进行处理。

接下来基于用户-商品-行为-时间四元组去重, 检查是否存在重复记录的数据, 发现存在重复四元组数量3843197条。删除重复, 每条只保留一行, 得到:

去重前行数: 12,256,906

去重后行数: 6,213,379

删除重复行: 6,043,527

统一时间格式, 补齐为 YYYY-MM-DD HH:00:00, 并校验时间有效性, 确保不存在转换失败的数据。时间范围从2025-11-18 00:00:00 到 2025-12-18 23:00:00, 时长一个月。确认时间变量已经被转换为datetime64类型。

3. 自动化数据检验脚本

为高效实现数据完整性、一致性、唯一性的批量检测, 定义函数, 实现自动化数据质量校验脚本。输出的数据检测报告如下:

```
=====
数据质量校验报告
=====

检测时间: 2026-09-07 00:07:37

数据总行数: 6213379

数据总列数: 5

完整性_缺失值检测: 通过

一致性_时间无效数量: 0

一致性_时间范围: 2025-11-18 00:00:00 至 2025-12-18 23:00:00

唯一性_检测结果: 通过, 无重复
```

```

完整性_缺失明细:
Empty DataFrame
Columns: [缺失数量, 缺失率%]
Index: []

一致性_ID变量检查:
      user_id  item_id
零值数量      0      0
负值数量      0      0

一致性_类别变量取值分布:

item_category:
item_category
3          2
8         496
10        129
21         88
28         61
...
14051      32
14056      15
14066     120
14074       4
14080      49
Name: count, Length: 8916, dtype: int64

behavior_type:
behavior_type
3      331350
1     5535879
2     239472
4      106678
Name: count, dtype: int64

```

4. 中间表构建

构建用户、商品、时间三个维度的基础聚合中间表。

其中用户维度中间表主键为user_id, 统计每个用户的整体行为, 包括总行为次数、各类行为次数(浏览、点击、购买等)、活跃天数、最早/最晚行为时间。

商品维度中间表主键为item_id, 统计每个商品的表现, 包括行为总次数、各类行为次数、独立用户数(多少用户进行过操作)、首次/最后出现时间。

时间维度中间表按日期聚合, 统计每天电商平台的整体情况, 包括行为总次数、各类行为次数、活跃用户数, 活跃商品数。

DataFrame总结如下：

用户维度中间表构建完成

用户数量: 10,000

商品维度中间表构建完成

商品数量: 2,876,947

时间维度中间表构建完成

日期数量: 31

为保证数据类型正确，对每一张表进行检查。时间表的 date 列还是 object，转成标准日期类型。至此完成全流程数据清洗以及中间表构建。将清洗后的用户行为主表和三张中间表以 Parquet格式输出。

三、EDA

本次用于研究的数据为：

用户数:10000

商品数:2876947

商品类目数:8916

时间:2025年11月18日-12月18日，维期一个月


各行为类型占比：

	behavior_type	行为名称	行为次数	占比百分比
0	1	浏览	5535879	89.10
1	2	收藏	239472	3.85
2	3	加购	331350	5.33
3	4	购买	106678	1.72

各行为类型中浏览占大多数。达到89.1%。其他三种行为中，加购占比5.33%，其次是浏览占比3.85%，购买最低，仅1.72%。

日活/周活趋势(当日)

当日有任何行为都计算入活跃用户。通过图像可以看到日活整体在波动中上升，在12月12日出现高峰，可能是由于双十二活动。周活以自然周进行计算，且对用户进行去重，只统计有多少用户当周有活跃行为。



用户活跃情况


将用户按活跃度类型进行分群统计。首先查看用户行为分布，根据统计数据将用户分为三类：

- 低活用户: 行为次数 ≤ 372 (中位数以下, 50%)
- 中活用户: $372 < \text{行为次数} \leq 1474$ (50%~90%, 40%)

- 高活用户:行为次数 > 1474 (90%以上, 10%)

然后进行统计,发现高活跃度用户仅占不到10%,低活跃度用户占比一半,其次是中活跃度用户占比达到40%。


从图表来看,用户活跃高峰期在晚上20-23点;早晨~中午时段活跃情况较稳定持平。用户最不活跃的时间在凌晨1~早晨7点。转化率(购买/总行为)在10点达到峰值,随后缓慢降低,从16点开始明显下降。



转化漏斗分析

由于淘宝app中收藏和加购实际上不存在先后关系(用户可能直接加购/购买而不收藏),为防止出现加购/购买用户数反而大于收藏数的情况,采用逐层筛选+递进,每一层要在上一层用户里进行筛选。

可以看出浏览-收藏环节流失率最高,有收藏行为的用户大部分会选择加购,而已经加购的用户很大一部分会选择购买。




用户分群分析

根据RFM分数将用户分为四类：


用户类型	R_score	F_score	M_score	定义
高价值	高(>=3)	高	高	最近活跃、频繁、购买多
潜力	高	低	低	最近活跃但行为少
流失	低	高	高	曾经活跃但现在不活跃
沉睡	低	低	低	长期不活跃、行为少

RFM用户分层占比



高价值用户占比35.6%，最多。其次是潜力用户，占比24.4%。流失用户占比22.4%，沉睡用户占比最小，为17.5%。


四类用户行为特征对比



整体而言，流失用户的四类行为平均次数要高于潜力用户。潜力用户的加购次数小于收藏次数，其他三类用户都是加购次数大于收藏次数。

时间维度分析

工作日和周末日均行为量较为接近，工作日行为量稍高，不排除是双十二当天为星期五的原因。双十二活动期间(12.11~12.13)日均活动量明显高出工作日和周末。



四、建模特征准备

1.时间窗口划分

时间窗口划分:为避免数据泄露,需要重新计算11.18~12.11(特征窗口)期间用户的特征,使用12.12~12.18(目标变量窗口)的数据计算目标变量。

特征窗口样本用户数为9,904, 其中在最后七天有购买行为的正样本占比: 66.17%。

2. 全维度特征体系构建

本阶段基于特征窗口构建特征,以防止数据泄漏。

本研究构建的特征体系及构建方法:

特征类别	特征名	含义	计算方法
用户生命周期	活跃度等级	用户活跃程度分档	按总行为次数分档：≤372（50%分位）低活，372~1474（50%~90%分位）中活，>1474高活
用户生命周期	连续活跃天数	用户最长连续活跃天数	用户活跃日期序列中最长的连续自然日天数
用户生命周期	流失间隔	距最后一次行为的天数	数据集最后一天 - 用户最后行为日期（天）
行为序列特征	平均行为间隔/小时	用户相邻行为的平均时间间隔	用户按时间排序后相邻行为时间差的平均值（小时）
兴趣特征	交互类目数	用户交互过的类目数量	该用户交互过的不同item_category去重计数
RFM	R	最近一次行为距今天数	数据集最后一天 - 用户最后行为日期
RFM	F	行为频率	用户总行为次数
RFM	M	购买次数（代金额）	用户购买行为（behavior_type=4）次数
RFM	R_score	R的1-5分	按R分位数打分，越小得分越高
RFM	F_score	F的1-5分	按F分位数打分，越大得分越高
RFM	M_score	M的1-5分	按M分位数打分，越大得分越高
RFM	RFM总分	用户价值总分	R_score + F_score + M_score
行为次数	浏览	浏览次数	behavior_type=1的次数
行为次数	收藏	收藏次数	behavior_type=2的次数
行为次数	加购	加购次数	behavior_type=3的次数
行为次数	购买	购买次数	behavior_type=4的次数
转化漏斗	浏览→加购	浏览到加购的转化率	加购次数 / 浏览次数
转化漏斗	加购→收藏	加购到收藏的转化率	收藏次数 / 加购次数
转化漏斗	收藏→购买	收藏到购买的转化率	购买次数 / 收藏次数
偏好特征	偏好强度得分	用户整体偏好强度	浏览×1 + 收藏×2 + 加购×3 + 购买×4
SVD隐式特征	svd_user_0 ~ svd_user_99	用户隐向量（100维）	基于用户-商品交互矩阵（行为加权：购买4/加购3/收藏2/浏览1），TruncatedSVD(k=100)分解

3. 样本构建与特征预处理


采用分层抽样按7:2:1划分训练集、验证集、测试集。对类别变量activity_level进行one-hot encoding; 分别对三个集合数据的数值型变量进行标准化。

4. 特征筛选

相关性热力图显示部分特征之间具有比较明显的相关性。

通过相关性分析检查特征之间相关性，删除相关性>0.95的高相关性特征：

- 删除churn_interval、view_count、preference_score: 保留recency即可
- 删除buy_count: 与研究定义的monetary(购买次数)定义相同




然后通过互信息法查看特征与目标变量的相关性。monetary(购买次数)互信息最高, 说明购买历史最直接预测未来购买。其次是rfm_score, 说明RFM综合分有效。SVD 多个维度排前列(svd_user_27、25、92...)——说明 SVD 隐向量确实有预测价值。favorite_count 最低, 说明收藏次数对未来购买预测力最弱。数据内没有互信息 < 0.01 的特征, 不用删除。

处理后的数据储存在文件夹: data_rady_for_modeling

五、传统机器学习模型

分别拟合逻辑回归、XGBoost、LightGBM模型作为基础模型。通过Optuna进行超参数自动调优后, 查看三个模型指标:

	AUC	准确率	召回率	F1
LogisticRegression	0.7654	0.7314	0.8885	0.8140
XGBoost	0.7738	0.7360	0.8809	0.8153
LightGBM	0.7759	0.7410	0.8809	0.8181



经 Optuna 超参数调优后，三种模型在测试集上的表现整体接近，AUC 均在 0.76~0.78 之间。LightGBM 的 AUC 最高，其次是 XGBoost 稍微低于 LightGBM。三者差距很小 (< 0.01)，模型复杂度带来的提升有限。其中 LightGBM 准确率 (0.7410) 最高，LR 召回率 (0.8885) 最高，但模型间的差距极小。从 F1 看，LightGBM 最高 (0.8181)，三个模型 F1 都在 0.81 左右，表现相似。

综合来说, 三个模型表现高度相似, 但AUC表现均不算优秀(没有>0.8), 可能的原因是数据量较小, 特征较少。考虑后续在更庞大的特征信号更强的数据集上进行研究。

六、深度学习模型

本项目先基于 GRU(门控循环单元)的序列模型进行用户未来7天购买行为预测。模型以11月18日至12月11日作为用户历史行为窗口, 以用户最近 20 次的行为序列为输入, 每个行为包含商品 ID 与行为类型两类信息。由于item_id维度较大, Embedding 矩阵参数巨大不好训练, 重新映射item_id为连续索引(1~228 万), 0 保留给 padding。设置早停, 连续三轮AUC无提升则停止。模型参数配置为: BCELoss作为损失函数, Adam优化器(学习率 0.001), 批大小为256, epoch=20, 通过CPU完成。最优AUC=0.5596, 效果较差且明显低于机器学习模型。

为进一步挖掘用户历史行为序列中的动态兴趣信息, 进一步引入深度兴趣网络(Deep Interest Network, DIN)进行用户未来7天购买行为预测。DIN模型关注如何从用户历史行为中准确理解真实的用户兴趣, 通过设置 Interest Extractor Layer挖掘用户行为背后隐藏的兴趣; 通过 Interest Evolving Layer 分析研究兴趣漂移和不同的兴趣演化轨迹(Zhou et.al, 2019)。但是本项目预测目标为用户级(未来7天是否购买), 因此将原DIN模型中“候选商品”query 历史行为改为“序列内部自我关注(self-attention)”, 仍可计算Attention动态加权, 输出用户整体兴趣表示。DIN模型以商品序列和行为序列为输入, Embedding 后映射为 16 维和 8 维向量; 通过自注意力层(含残差连接和层归一化)动态加权序列; 对序列维度取平均聚合为用户表示; 最后经全连接层输出购买概率。模型总参数量约 3661 万。连续三轮AUC无提升则停止。结果显示, 验证集最佳AUC=0.5810, 并不理想。

总结来说, 深度学习模型效果欠佳可能的原因有二: 其一是序列信息本身预测力弱, 不如加入聚合特征的机器学习模型。其次, 数据规模小, 训练集仅 6932 条, 深度模型难以充分发挥, 且易过拟合。

本项目数据用户-商品交互矩阵稀疏度 99.98%，且SVD 解释方差比仅 0.10，前 100 个主成分只能解释 10% 的方差。Cheng et.al (2016) 研究提出，具有嵌入的神经网络在用户-项目交互稀疏且高秩时可能会过度泛化，相比之下，较好的选择是联合训练宽线性模型和神经网络的Wide & Deep学习。

七、Stacking模型融合

由于深度学习模型效果不理想，因此采用Stacking策略融合传统机器学习模型进一步优化效果。融合逻辑回归与XGBoost作为第一层基模型，通过5折分层交叉生成OOF(Out-of-Fold)预测，以其预测概率作为第二层元模型(逻辑回归)的输入特征，最终输出融合预测结果。二者权重为(LR, XGB): [1.95722768 3.09358669]

与单模型对比（验证集）：

	AUC	准确率	召回率	F1
LogisticRegression	0.7654	0.7314	0.8885	0.8140
XGBoost	0.7738	0.7360	0.8809	0.8153
Stacking	0.7729	0.7309	0.8771	0.8117

Stacking模型AUC=0.7729，介于两个基础模型之间。准确率、召回率与F1同样处于两者之间，未超过最优模型XGBoost。可见在本研究数据上，Stacking融合未能带来性能提升。可能原因如下：

- 逻辑回归与XGBoost的模型效果本身高度相似，融合的增益有限
- 数据规模较小，模型不足以优化到更准确的预测

八、模型可解释性分析


1. 逻辑回归特征系数

逻辑回归中，购买次评分m-score对用户未来7天购买决策具有最强正向影响，用户历史购买多则未来更可能买。其次是最近活跃度recency，具有明显负向作用(注意数据处理时进行过逆


排序), 说明距上次行为越久(值越大)则越不可能购买。活跃度相关特征如

active_streak_days、rfm_score均存在正向作用, 越是最近活跃、连续活跃天数高的用户越可能购买。此外其他未来更可能发生购买行为的用户特征为:

- 浏览→加购转化率高
- 加购次数多
- 交互类目多



从XGBoost sharp图中可得，对预测最重要的特征是monetary购买次数，其次依次是RFM score、recency、m_score和浏览→加购转化率。购买次数越多，用户未来7天越可能出现购买行为。RFM评分越高，未来越可能购买。recency值越大越不可能购买，意味着最近活跃度越低越不可能购买。展示出的用户购买决策核心特点与LR模型一致。



混淆矩阵显示，模型在精准识别购买用户方面表现较好，在识别实际不会购买的用户方面表现欠缺。可能是由于数据中正样本占66%左右。实际业务中，FP和FN 用户对应不同的业务成本：FP 导致营销资源浪费，FN 导致错失销售机会。未来可结合业务目标调整样本平衡。

XGBoost能够较好的识别预测和实际均购买的“高意向用户”，这部分用户可直接作为精准营销、优惠券发放的目标人群。对于模型预测不买，实际也不买的低意向冷冻用户，可尝试通过短信/邮件营销尝试唤醒，但不宜投入过多资源。模型预测会购买但实际未购买的用户是分析原因与挽回操作的重点，这类人群表现出兴趣特征但是并未转化，可能原因包括：价格敏感、竞品竞争、缺少促销刺激等。针对这类用户，可采取定向优惠、限时折扣、购物车提醒等转化促进手段，挽回成本相对较低。另外一部分行为特征不典型，模型未能识别其购买意向但实际上购买的用户也值得研究，有助于发现模型遗漏的潜在购买模式，改进特征工程；或定位其购买的商品类别，分析商品特征及吸引用户的原因。

九、A/B Testing模拟

实验设计

针对模型预测"不会购买"的用户设计挽留策略, 通过离线模拟 A/B 测试评估投放优惠券的经济效果。测试集总用户数991人, 实验对象为测试集中模型预测不购买的用户, 共 234 人。

对照组: 不投放, 用户维持原有行为

实验组: 对该群体投放优惠券, 假设挽回率为50%(即原本不买的用户中有50% 因优惠券刺激而转化)

参数假设:

- 客单价 100 元, 单张券成本30元
- $GMV(\text{成交总额}) = \text{购买人数} \times \text{客单价}$
- $\text{总ROI} = \text{实验组 GMV} / \text{投放成本}$
- $\text{增量ROI} = (\text{实验组GMV} - \text{对照组GMV}) / \text{投放成本}$

结果显示, 实验组净利润 8,480 元, 相比对照组增加 980 元, 投放策略整体有效, 实现盈利。

在 50% 挽回率下, 原本不买的 159 人中有 80 人被成功挽回, 购买人数从 75 人提升至 155 人, 增幅达 107%。增量 ROI 为 1.14, 略高于盈亏平衡点。每投入 1 元券成本, 带来 1.14 元的增量 GMV。

其他条件不变, 尝试多种挽回率, 发现30%挽回率下实现盈亏平衡。在实际应用中, 控制券成本、提升优惠吸引力以提高挽回率都是提升利润的重要手段。此外, 本测试聚焦于全部预测不买的用户, 实际上可进一步对用户进行细分(如冷冻用户, 过去活跃但现在不活跃等), 根据该群体特点进行精准营销。

十、局限性

1. 数据量较少, 导致机器学习模型调优效果有限, 深度学习、DIN模型拟合预测效果差。

2. 数据本身序列信息本身预测力弱，不适合深度学习模型。
3. 整体样本中正样本占比较大，导致最优模型XGBoost对于正样本预测表现较好，但负样本预测能力较弱，后续可考虑先对样本进行平衡。

Enhancement 改进方向：

数据改进

1. 扩充数据规模。通过增加样本量、拉长时间跨度等方式捕捉更长周期的行为模式。
2. 补充用户的人口统计学特征(如年龄、性别、居住地等)，打造用户画像。接入更多商品特征价格、品牌等，更好的预测用户潜在兴趣模式和导向。
3. 修正样本偏差，保证数据正负样本平衡。

特征工程改进

1. 引入 SMOTE 过采样处理样本不平衡问题。
2. 当前 GRU/DIN 仅用行为序列，未与 118 个聚合特征结合，可尝试将序列表示与 RFM、活跃度等聚合特征拼接，构建融合模型。
3. SVD 解释方差比低，隐向量信息量有限，原因是用户-商品交互矩阵极度稀疏。换更合适的矩阵分解算法(如SVD++、贝叶斯排序等)。

建模改进

1. 尝试通过构造强特征提升模型上限
2. 尝试其他序列模型(如 Transformer)，提升学习预测效果
3. 尝试 Wide & Deep learning framework (Cheng et.al, 2016)

营销模拟改进

1. 引入因果推断，更好的考察用户购买行为和营销手段之间的因果关系。

AI使用情况描述

本研究使用 Generative AI用于以下情况：

- 研究方案优化建议参考
- 代码调试纠错
- 代码打包整理
- 图表美化
- 研究提升建议参考

References

Cheng, H. T., Koc, L., Harmsen, J., Shaked, T., Chandra, T., Aradhye, H., ... & Shah, H. (2016, September). Wide & deep learning for recommender systems. In *Proceedings of the 1st workshop on deep learning for recommender systems* (pp. 7-10).

Zhou, G., Mou, N., Fan, Y., Pi, Q., Bian, W., Zhou, C., ... & Gai, K. (2019, July). Deep interest evolution network for click-through rate prediction. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 33, No. 01, pp. 5941-5948).